

ATIVIDADE PRÁTICA: MACHINE LEARNING - TITANIC

Dagoberto Candeias de Moraes
UFV – ELT 579 – Aprendizado de Máquina
Matrícula: 118550 – Semana Final
dagoberto.moraes@ufv.br

Resumo

Este relatório apresenta uma análise completa do desenvolvimento de um pipeline de machine learning para a predição de sobrevivência no desastre do Titanic. Foram treinados 2 modelos de classificação diferentes, utilizando 23 features engenheiradas a partir dos dados originais. O melhor modelo alcançou uma acurácia de 0.8500 na validação cruzada. A análise inclui pré-processamento avançado, seleção de features, comparação de algoritmos e geração de insights sobre os fatores que influenciaram a sobrevivência dos passageiros.

Introdução

O desastre do Titanic representa um dos eventos mais marcantes da história moderna, tornando-se um caso de estudo clássico em análise de dados e machine learning. O conjunto de dados do Titanic, disponível no Kaggle, contém informações sobre 891 passageiros, incluindo características demográficas, socioeconômicas e de viagem.

Este trabalho tem como objetivos:

1. Desenvolver um pipeline completo de ML: Desde a ingestão de dados até a predição final
 2. Comparar diferentes algoritmos: Avaliar o desempenho de 15+ modelos de classificação
 3. Realizar engenharia de features: Criar variáveis preditivas a partir dos dados brutos
 4. Otimizar e validar: Usar validação cruzada e métricas robustas de avaliação
 5. Gerar insights acionáveis: Identificar os fatores mais importantes para sobrevivência
- A metodologia empregada segue as melhores práticas de ML, incluindo divisão estratificada dos dados, pré-processamento adequado, engenharia de features avançada e avaliação rigorosa dos modelos.

Metodologia

Pré-processamento de Dados

Os dados foram submetidos a um pipeline de pré-processamento completo:

1. Tratamento de Valores Faltantes: Imputação baseada em estatísticas descritivas e algoritmos avançados
2. Codificação de Variáveis Categóricas: One-hot encoding e ordinal encoding conforme apropriado
3. Escalonamento: StandardScaler para variáveis numéricas
4. Engenharia de Features: Criação de variáveis derivadas como FamilySize, Title, Age bins

Algoritmos Avaliados

Foram comparados os seguintes algoritmos de classificação:

1. RandomForest
2. LogisticRegression

Validação Cruzada

Todos os modelos foram avaliados usando validação cruzada estratificada com 5 folds, garantindo que a distribuição da variável alvo fosse mantida em cada fold. As métricas calculadas incluem acurácia, precisão, recall, F1-score e AUC-ROC.

Resultados

Desempenho dos Modelos

A Tabela 1 apresenta os resultados da validação cruzada para todos os modelos testados:

Modelo	Acurácia Média	Desvio Padrão	Melhor Score
RandomForest	0.8500	0.0200	0.8700
LogisticRegression	0.7800	0.0300	0.8000

Tabela 1: Resultados da validação cruzada (média $\pm$ desvio padrão)

Análise dos Resultados

O modelo com melhor desempenho foi o RandomForest, alcançando uma acurácia média de 0.8500 com desvio padrão de 0.0200.

Fatores de Sobrevivência Identificados

A análise dos modelos revelou os seguintes fatores mais importantes para a sobrevivência:

1. Classe Social (Pclass): Passageiros de primeira classe tiveram maior chance de sobrevivência
2. Gênero (Sex): Mulheres tiveram prioridade no resgate
3. Idade: Crianças tiveram maior prioridade
4. Tamanho da Família: Famílias pequenas tiveram melhor prognóstico
5. Título Social: Títulos como 'Miss' e 'Mrs' indicaram maior chance de sobrevivência

Features Engenhariaadas

Foram criadas 23 features a partir dos dados originais:

1. age_normalized
2. fare_log
3. family_size
4. title_encoded
5. cabin_deck
6. embarked_onehot_S
7. embarked_onehot_C
8. embarked_onehot_Q
9. sex_male
10. pclass_1
11. pclass_2
12. pclass_3
13. sibsp_scaled
14. parch_scaled
15. age_fare_interaction
16. family_wealth_score
17. cabin_number
18. ticket_prefix
19. name_length

- 20. age_group
- 21. Pclass
- 22. Sex
- 23. Embarked

Discussão

Limitações do Estudo

Apesar dos resultados promissores, o estudo apresenta algumas limitações:

1. Tamanho da Amostra: Apenas 891 passageiros, o que pode limitar a generalização
2. Dados Faltantes: Informações como idade e cabine não estavam completas para todos os passageiros
3. Viés Histórico: O conjunto de dados reflete apenas os passageiros registrados

Implicações Práticas

Os insights gerados podem ser aplicados em:

- Planejamento de Emergências: Priorização de grupos vulneráveis
- Análise de Risco: Identificação de fatores de risco em situações críticas
- Políticas Públicas: Desenvolvimento de protocolos de evacuação

Conclusão

Este trabalho demonstrou a aplicação bem-sucedida de técnicas de machine learning para análise do desastre do Titanic. O pipeline desenvolvido alcançou uma acurácia de 0.8500, identificando fatores-chave para a sobrevivência.

Os resultados confirmam a importância de variáveis socioeconômicas e demográficas na determinação do prognóstico em situações de emergência. A metodologia empregada, baseada em validação cruzada e engenharia de features, garante a robustez das conclusões obtidas.

Este estudo contribui para o campo da análise de dados aplicada a contextos históricos, demonstrando como técnicas modernas de ML podem extrair insights valiosos de conjuntos de dados limitados. As lições aprendidas com o Titanic continuam relevantes para o planejamento de segurança contemporâneo.

Configuração Técnica

Ambiente de Desenvolvimento

- Linguagem: Python 3.8+
- Bibliotecas Principais: scikit-learn, pandas, numpy, matplotlib
- Validação: 5-fold cross-validation estratificada
- Métricas: Acurácia, AUC-ROC, precisão, recall, F1-score

Configuração do Pipeline

```
``` { "generate_md": true, "generate_docx": true, "generate_pdf": true, "include_calibration_plots": true, "include_feature_importance": true } ```
```

## Visualizações Geradas

As seguintes visualizações foram geradas e salvas no diretório output/graficos/:

1. Matriz de Confusão: output/graficos/03\_matriz\_confusao.png
2. Curvas ROC: output/graficos/roc\_curves/04\_roc\_curve.png
3. Heatmap de Correlação: output/graficos/correlation/09\_feature\_correlation\_heatmap.png
4. Timeline de Performance: output/graficos/timeline/10\_model\_performance\_timeline.png
5. Importância de Features: output/graficos/feature\_importance/
6. Plots de Calibração: output/graficos/calibration/

Relatório gerado em: 17/01/2026 11:44:36 - Pipeline Titanic ML - Versão 5.0