

ATIVIDADE PRÁTICA: MACHINE LEARNING - TITANIC

Dagoberto Candeias de Moraes
UFV – ELT 579 – Aprendizado de Máquina
Matrícula: 118550 – Semana Final
dagoberto.moraes@ufv.br

Resumo

Este relatório apresenta uma análise completa do desenvolvimento de um pipeline de machine learning para a predição de sobrevivência no desastre do Titanic. Foram treinados 22 modelos de classificação diferentes, utilizando 28 features engenheiradas a partir dos dados originais. O melhor modelo alcançou uma acurácia de 0.8373 na validação cruzada. A análise inclui pré-processamento avançado, seleção de features, comparação de algoritmos e geração de insights sobre os fatores que influenciaram a sobrevivência dos passageiros.

Introdução

O desastre do Titanic representa um dos eventos mais marcantes da história moderna, tornando-se um caso de estudo clássico em análise de dados e machine learning. O conjunto de dados do Titanic, disponível no Kaggle, contém informações sobre 891 passageiros, incluindo características demográficas, socioeconômicas e de viagem.

Este trabalho tem como objetivos:

1. Desenvolver um pipeline completo de ML: Desde a ingestão de dados até a predição final
 2. Comparar diferentes algoritmos: Avaliar o desempenho de 15+ modelos de classificação
 3. Realizar engenharia de features: Criar variáveis preditivas a partir dos dados brutos
 4. Otimizar e validar: Usar validação cruzada e métricas robustas de avaliação
 5. Gerar insights acionáveis: Identificar os fatores mais importantes para sobrevivência
- A metodologia empregada segue as melhores práticas de ML, incluindo divisão estratificada dos dados, pré-processamento adequado, engenharia de features avançada e avaliação rigorosa dos modelos.

Metodologia

Pré-processamento de Dados

Os dados foram submetidos a um pipeline de pré-processamento completo:

1. Tratamento de Valores Faltantes: Imputação baseada em estatísticas descritivas e algoritmos avançados
2. Codificação de Variáveis Categóricas: One-hot encoding e ordinal encoding conforme apropriado
3. Escalonamento: StandardScaler para variáveis numéricas
4. Engenharia de Features: Criação de variáveis derivadas como FamilySize, Title, Age bins

Algoritmos Avaliados

Foram comparados os seguintes algoritmos de classificação:

1. RandomForest
2. LogisticRegression
3. SVC
4. KNeighbors
5. GaussianNB
6. MLPClassifier
7. GradientBoosting
8. ExtraTrees
9. AdaBoost
10. Bagging

11. SGDClassifier
12. RidgeClassifier
13. LinearSVC
14. DecisionTree
15. BernoulliNB
16. LinearDiscriminantAnalysis
17. QuadraticDiscriminantAnalysis
18. XGBoost
19. LightGBM
20. CatBoost
21. VotingEnsemble
22. StackingEnsemble

Validação Cruzada

Todos os modelos foram avaliados usando validação cruzada estratificada com 5 folds, garantindo que a distribuição da variável alvo fosse mantida em cada fold. As métricas calculadas incluem acurácia, precisão, recall, F1-score e AUC-ROC.

Resultados

Desempenho dos Modelos

A Tabela 1 apresenta os resultados da validação cruzada para todos os modelos testados:

Modelo	Acurácia Média	Desvio Padrão	Melhor Score
LogisticRegression	0.8373	0.0079	0.8485
LinearSVC	0.8350	0.0110	0.8485
SVC	0.8339	0.0088	0.8418
RidgeClassifier	0.8316	0.0073	0.8384
VotingEnsemble	0.8316	0.0099	0.8418
SGDClassifier	0.8294	0.0088	0.8418
CatBoost	0.8283	0.0145	0.8418
StackingEnsemble	0.8283	0.0099	0.8384
RandomForest	0.8260	0.0084	0.8350
GradientBoosting	0.8238	0.0161	0.8384
XGBoost	0.8215	0.0287	0.8451
ExtraTrees	0.8193	0.0063	0.8283
AdaBoost	0.8182	0.0073	0.8283
Bagging	0.8171	0.0151	0.8384
LightGBM	0.8159	0.0294	0.8384
MLPClassifier	0.8103	0.0260	0.8350

BernoulliNB	0.8103	0.0278	0.8316
LinearDiscriminantAnalysis	0.8103	0.0289	0.8451
KNeighbors	0.8047	0.0172	0.8283
DecisionTree	0.8036	0.0161	0.8182
QuadraticDiscriminantAnalysis	0.7172	0.0172	0.7340
GaussianNB	0.6049	0.0141	0.6195

Tabela 1: Resultados da validação cruzada (média $\pm$ desvio padrão)

Análise dos Resultados

O modelo com melhor desempenho foi o LogisticRegression, alcançando uma acurácia média de 0.8373 com desvio padrão de 0.0079.

Fatores de Sobrevivência Identificados

A análise dos modelos revelou os seguintes fatores mais importantes para a sobrevivência:

1. Classe Social (Pclass): Passageiros de primeira classe tiveram maior chance de sobrevivência
2. Gênero (Sex): Mulheres tiveram prioridade no resgate
3. Idade: Crianças tiveram maior prioridade
4. Tamanho da Família: Famílias pequenas tiveram melhor prognóstico
5. Título Social: Títulos como 'Miss' e 'Mrs' indicaram maior chance de sobrevivência

Features Engenhariaadas

Foram criadas 28 features a partir dos dados originais:

1. Pclass
2. Name
3. Sex
4. Age
5. SibSp
6. Parch
7. Ticket
8. Fare
9. Cabin
10. Embarked
11. Title
12. Title_Group
13. FamilySize
14. IsAlone
15. AgeGroup
16. FareGroup
17. CabinDeck
18. TicketFreq
19. Age*Pclass
20. FarePerPerson
21. Title*Pclass
22. Age*Sex

- 23. FamilySizeCat
- 24. Age^2
- 25. Fare^2
- 26. Age*Fare
- 27. Title_encoded
- 28. CabinDeck_encoded

Discussão

Limitações do Estudo

Apesar dos resultados promissores, o estudo apresenta algumas limitações:

1. Tamanho da Amostra: Apenas 891 passageiros, o que pode limitar a generalização
2. Dados Faltantes: Informações como idade e cabine não estavam completas para todos os passageiros
3. Viés Histórico: O conjunto de dados reflete apenas os passageiros registrados

Implicações Práticas

Os insights gerados podem ser aplicados em:

- Planejamento de Emergências: Priorização de grupos vulneráveis
- Análise de Risco: Identificação de fatores de risco em situações críticas
- Políticas Públicas: Desenvolvimento de protocolos de evacuação

Conclusão

Este trabalho demonstrou a aplicação bem-sucedida de técnicas de machine learning para análise do desastre do Titanic. O pipeline desenvolvido alcançou uma acurácia de 0.8373, identificando fatores-chave para a sobrevivência.

Os resultados confirmam a importância de variáveis socioeconômicas e demográficas na determinação do prognóstico em situações de emergência. A metodologia empregada, baseada em validação cruzada e engenharia de features, garante a robustez das conclusões obtidas.

Este estudo contribui para o campo da análise de dados aplicada a contextos históricos, demonstrando como técnicas modernas de ML podem extrair insights valiosos de conjuntos de dados limitados. As lições aprendidas com o Titanic continuam relevantes para o planejamento de segurança contemporâneo.

Configuração Técnica

Ambiente de Desenvolvimento

- Linguagem: Python 3.8+
- Bibliotecas Principais: scikit-learn, pandas, numpy, matplotlib
- Validação: 5-fold cross-validation estratificada
- Métricas: Acurácia, AUC-ROC, precisão, recall, F1-score

Configuração do Pipeline

```
``` { "debug_mode": true, "random_state": 25, "parallel_jobs": 1, "cv_folds": 3, "cache_enabled": false,
"fast_mode": true, "feature_selection": false, "run_smoke_tests": true, "optuna_trials": 0,
"use_knn_imputation": true, "enhanced_balance": false, "generate_all_plots": true, "log_level": 20,
"max_features_for_shap": 100, "kfold_te_splits": 5, "smote_k": 5, "smote_strategy": "auto",
"calibration_method": "isotonic", "calibration_cv": 3, "permutation_repeats": 5, "randomized_n_iter":
100, "report_include_images": true, "selection_threshold": 0.01, "te_prior": 10, "use_optuna": false } ```
```

## Visualizações Geradas

As seguintes visualizações foram geradas e salvas no diretório output/graficos/:

1. Matriz de Confusão: output/graficos/03\_matriz\_confusao.png
2. Curvas ROC: output/graficos/roc\_curves/04\_roc\_curve.png
3. Heatmap de Correlação: output/graficos/correlation/09\_feature\_correlation\_heatmap.png
4. Timeline de Performance: output/graficos/timeline/10\_model\_performance\_timeline.png
5. Importância de Features: output/graficos/feature\_importance/
6. Plots de Calibração: output/graficos/calibration/

Relatório gerado em: 17/01/2026 16:16:54 - Pipeline Titanic ML - Versão 5.0