

# **ATIVIDADE PRÁTICA: MACHINE LEARNING - TITANIC**

Dagoberto Candeias de Moraes  
UFV – ELT 579 – Aprendizado de Máquina  
Matrícula: 118550 – Semana Final  
dagoberto.moraes@ufv.br

## Resumo

Este relatório apresenta uma análise completa do desenvolvimento de um pipeline de machine learning para a predição de sobrevivência no desastre do Titanic. Foram treinados 15 modelos de classificação diferentes, utilizando 23 features engenheiradas a partir dos dados originais. O melhor modelo alcançou uma acurácia de 0.8283 na validação cruzada. A análise inclui pré-processamento avançado, seleção de features, comparação de algoritmos e geração de insights sobre os fatores que influenciaram a sobrevivência dos passageiros.

## Introdução

O desastre do Titanic representa um dos eventos mais marcantes da história moderna, tornando-se um caso de estudo clássico em análise de dados e machine learning. O conjunto de dados do Titanic, disponível no Kaggle, contém informações sobre 891 passageiros, incluindo características demográficas, socioeconômicas e de viagem.

Este trabalho tem como objetivos:

1. Desenvolver um pipeline completo de ML: Desde a ingestão de dados até a predição final
  2. Comparar diferentes algoritmos: Avaliar o desempenho de 15+ modelos de classificação
  3. Realizar engenharia de features: Criar variáveis preditivas a partir dos dados brutos
  4. Otimizar e validar: Usar validação cruzada e métricas robustas de avaliação
  5. Gerar insights acionáveis: Identificar os fatores mais importantes para sobrevivência
- A metodologia empregada segue as melhores práticas de ML, incluindo divisão estratificada dos dados, pré-processamento adequado, engenharia de features avançada e avaliação rigorosa dos modelos.

## Metodologia

### Pré-processamento de Dados

Os dados foram submetidos a um pipeline de pré-processamento completo:

1. Tratamento de Valores Faltantes: Imputação baseada em estatísticas descritivas e algoritmos avançados
2. Codificação de Variáveis Categóricas: One-hot encoding e ordinal encoding conforme apropriado
3. Escalonamento: StandardScaler para variáveis numéricas
4. Engenharia de Features: Criação de variáveis derivadas como FamilySize, Title, Age bins

### Algoritmos Avaliados

Foram comparados os seguintes algoritmos de classificação:

1. RandomForest
2. LogisticRegression
3. SVC
4. MLPClassifier
5. GradientBoosting
6. ExtraTrees
7. AdaBoost
8. Bagging
9. SGDClassifier
10. RidgeClassifier

- 11. LinearSVC
- 12. DecisionTree
- 13. XGBoost
- 14. LightGBM
- 15. CatBoost

## Validação Cruzada

Todos os modelos foram avaliados usando validação cruzada estratificada com 5 folds, garantindo que a distribuição da variável alvo fosse mantida em cada fold. As métricas calculadas incluem acurácia, precisão, recall, F1-score e AUC-ROC.

## Resultados

### Desempenho dos Modelos

A Tabela 1 apresenta os resultados da validação cruzada para todos os modelos testados:

| Modelo             | Acurácia Média | Desvio Padrão | Melhor Score |
|--------------------|----------------|---------------|--------------|
| SVC                | 0.8283         | 0.0120        | 0.8384       |
| RidgeClassifier    | 0.8227         | 0.0032        | 0.8249       |
| AdaBoost           | 0.8182         | 0.0126        | 0.8316       |
| LinearSVC          | 0.8171         | 0.0151        | 0.8350       |
| LogisticRegression | 0.8159         | 0.0151        | 0.8350       |
| CatBoost           | 0.8126         | 0.0271        | 0.8350       |
| SGDClassifier      | 0.8114         | 0.0317        | 0.8418       |
| MLPClassifier      | 0.8092         | 0.0222        | 0.8249       |
| LightGBM           | 0.8047         | 0.0153        | 0.8215       |
| GradientBoosting   | 0.8036         | 0.0183        | 0.8182       |
| XGBoost            | 0.7980         | 0.0167        | 0.8114       |
| RandomForest       | 0.7969         | 0.0240        | 0.8215       |
| Bagging            | 0.7969         | 0.0195        | 0.8182       |
| ExtraTrees         | 0.7755         | 0.0231        | 0.8081       |
| DecisionTree       | 0.7609         | 0.0198        | 0.7879       |

Tabela 1: Resultados da validação cruzada (média ± desvio padrão)

### Análise dos Resultados

O modelo com melhor desempenho foi o SVC, alcançando uma acurácia média de 0.8283 com desvio padrão de 0.0120.

## Fatores de Sobrevivência Identificados

A análise dos modelos revelou os seguintes fatores mais importantes para a sobrevivência:

1. Classe Social (Pclass): Passageiros de primeira classe tiveram maior chance de sobrevivência
2. Gênero (Sex): Mulheres tiveram prioridade no resgate
3. Idade: Crianças tiveram maior prioridade
4. Tamanho da Família: Famílias pequenas tiveram melhor prognóstico
5. Título Social: Títulos como 'Miss' e 'Mrs' indicaram maior chance de sobrevivência

## Features Engenhariaadas

Foram criadas 23 features a partir dos dados originais:

1. Pclass
2. Sex
3. Age
4. SibSp
5. Parch
6. Fare
7. Embarked
8. FamilySize
9. IsAlone
10. TicketPrefix
11. feat\_AgeBin
12. feat\_FareBin
13. feat\_AgeCategory\_v2
14. feat\_FareCategory\_v2
15. feat\_Age\_missing
16. feat\_Cabin\_missing
17. feat\_Embarked\_missing
18. feat\_Fare\_missing
19. feat\_Pclass\_te
20. feat\_Sex\_te
21. feat\_Embarked\_te
22. feat\_Title\_te
23. feat\_TicketPrefix\_te

## Discussão

### Limitações do Estudo

Apesar dos resultados promissores, o estudo apresenta algumas limitações:

1. Tamanho da Amostra: Apenas 891 passageiros, o que pode limitar a generalização
2. Dados Faltantes: Informações como idade e cabine não estavam completas para todos os passageiros
3. Viés Histórico: O conjunto de dados reflete apenas os passageiros registrados

### Implicações Práticas

Os insights gerados podem ser aplicados em:

- Planejamento de Emergências: Priorização de grupos vulneráveis

- Análise de Risco: Identificação de fatores de risco em situações críticas
- Políticas Públicas: Desenvolvimento de protocolos de evacuação

## Conclusão

Este trabalho demonstrou a aplicação bem-sucedida de técnicas de machine learning para análise do desastre do Titanic. O pipeline desenvolvido alcançou uma acurácia de 0.8283, identificando fatores-chave para a sobrevivência.

Os resultados confirmam a importância de variáveis socioeconômicas e demográficas na determinação do prognóstico em situações de emergência. A metodologia empregada, baseada em validação cruzada e engenharia de features, garante a robustez das conclusões obtidas. Este estudo contribui para o campo da análise de dados aplicada a contextos históricos, demonstrando como técnicas modernas de ML podem extrair insights valiosos de conjuntos de dados limitados. As lições aprendidas com o Titanic continuam relevantes para o planejamento de segurança contemporâneo.

## Configuração Técnica

### Ambiente de Desenvolvimento

- Linguagem: Python 3.8+
- Bibliotecas Principais: scikit-learn, pandas, numpy, matplotlib
- Validação: 5-fold cross-validation estratificada
- Métricas: Acurácia, AUC-ROC, precisão, recall, F1-score

### Configuração do Pipeline

```
```{}```
```

## Visualizações Geradas

As seguintes visualizações foram geradas e salvas no diretório output/graficos/:

1. Matriz de Confusão: output/graficos/03\_matriz\_confusao.png
2. Curvas ROC: output/graficos/roc\_curves/04\_roc\_curve.png
3. Heatmap de Correlação: output/graficos/correlation/09\_feature\_correlation\_heatmap.png
4. Timeline de Performance: output/graficos/timeline/10\_model\_performance\_timeline.png
5. Importância de Features: output/graficos/feature\_importance/
6. Plots de Calibração: output/graficos/calibration/

Relatório gerado em: 04/01/2026 20:01:02 - Pipeline Titanic ML - Versão 5.0