

ATIVIDADE PRÁTICA: MACHINE LEARNING - TITANIC

Dagoberto Candeias de Moraes
UFV – ELT 579 – Aprendizado de Máquina
Matrícula: 118550 – Semana Final
dagoberto.moraes@ufv.br

Resumo

Este relatório apresenta uma análise completa do desenvolvimento de um pipeline de machine learning para a predição de sobrevivência no desastre do Titanic. Foram treinados 15 modelos de classificação diferentes, utilizando 23 features engenheiradas a partir dos dados originais. O melhor modelo alcançou uma acurácia de 0.8283 na validação cruzada. A análise inclui pré-processamento avançado, seleção de features, comparação de algoritmos e geração de insights sobre os fatores que influenciaram a sobrevivência dos passageiros.

Introdução

O desastre do Titanic representa um dos eventos mais marcantes da história moderna, tornando-se um caso de estudo clássico em análise de dados e machine learning. O conjunto de dados do Titanic, disponível no Kaggle, contém informações sobre 891 passageiros, incluindo características demográficas, socioeconômicas e de viagem.

Este trabalho tem como objetivos:

1. Desenvolver um pipeline completo de ML: Desde a ingestão de dados até a predição final
 2. Comparar diferentes algoritmos: Avaliar o desempenho de 15+ modelos de classificação
 3. Realizar engenharia de features: Criar variáveis preditivas a partir dos dados brutos
 4. Otimizar e validar: Usar validação cruzada e métricas robustas de avaliação
 5. Gerar insights acionáveis: Identificar os fatores mais importantes para sobrevivência
- A metodologia empregada segue as melhores práticas de ML, incluindo divisão estratificada dos dados, pré-processamento adequado, engenharia de features avançada e avaliação rigorosa dos modelos.

Metodologia

Pré-processamento de Dados

Os dados foram submetidos a um pipeline de pré-processamento completo:

1. Tratamento de Valores Faltantes: Imputação baseada em estatísticas descritivas e algoritmos avançados
2. Codificação de Variáveis Categóricas: One-hot encoding e ordinal encoding conforme apropriado
3. Escalonamento: StandardScaler para variáveis numéricas
4. Engenharia de Features: Criação de variáveis derivadas como FamilySize, Title, Age bins

Algoritmos Avaliados

Foram comparados os seguintes algoritmos de classificação:

1. RandomForest
2. LogisticRegression
3. SVC
4. MLPClassifier
5. GradientBoosting
6. ExtraTrees
7. AdaBoost
8. Bagging
9. SGDClassifier
10. RidgeClassifier

- 11. LinearSVC
- 12. DecisionTree
- 13. XGBoost
- 14. LightGBM
- 15. CatBoost

Validação Cruzada

Todos os modelos foram avaliados usando validação cruzada estratificada com 5 folds, garantindo que a distribuição da variável alvo fosse mantida em cada fold. As métricas calculadas incluem acurácia, precisão, recall, F1-score e AUC-ROC.

Resultados

Desempenho dos Modelos

A Tabela 1 apresenta os resultados da validação cruzada para todos os modelos testados:

Modelo	Acurácia Média	Desvio Padrão	Melhor Score
SVC	0.8283	0.0120	0.8384
RidgeClassifier	0.8227	0.0032	0.8249
AdaBoost	0.8182	0.0126	0.8316
LinearSVC	0.8171	0.0151	0.8350
LogisticRegression	0.8159	0.0151	0.8350
CatBoost	0.8126	0.0271	0.8350
SGDClassifier	0.8114	0.0317	0.8418
MLPClassifier	0.8092	0.0222	0.8249
LightGBM	0.8047	0.0153	0.8215
GradientBoosting	0.8036	0.0183	0.8182
XGBoost	0.7980	0.0167	0.8114
RandomForest	0.7969	0.0240	0.8215
Bagging	0.7969	0.0195	0.8182
ExtraTrees	0.7755	0.0231	0.8081
DecisionTree	0.7609	0.0198	0.7879

Tabela 1: Resultados da validação cruzada (média ± desvio padrão)

Análise dos Resultados

O modelo com melhor desempenho foi o SVC, alcançando uma acurácia média de 0.8283 com desvio padrão de 0.0120.

Fatores de Sobrevivência Identificados

A análise dos modelos revelou os seguintes fatores mais importantes para a sobrevivência:

1. Classe Social (Pclass): Passageiros de primeira classe tiveram maior chance de sobrevivência
2. Gênero (Sex): Mulheres tiveram prioridade no resgate
3. Idade: Crianças tiveram maior prioridade
4. Tamanho da Família: Famílias pequenas tiveram melhor prognóstico
5. Título Social: Títulos como 'Miss' e 'Mrs' indicaram maior chance de sobrevivência

Features Engenhariaadas

Foram criadas 23 features a partir dos dados originais:

1. Pclass
2. Sex
3. Age
4. SibSp
5. Parch
6. Fare
7. Embarked
8. FamilySize
9. IsAlone
10. TicketPrefix
11. feat_AgeBin
12. feat_FareBin
13. feat_AgeCategory_v2
14. feat_FareCategory_v2
15. feat_Age_missing
16. feat_Cabin_missing
17. feat_Embarked_missing
18. feat_Fare_missing
19. feat_Pclass_te
20. feat_Sex_te
21. feat_Embarked_te
22. feat_Title_te
23. feat_TicketPrefix_te

Discussão

Limitações do Estudo

Apesar dos resultados promissores, o estudo apresenta algumas limitações:

1. Tamanho da Amostra: Apenas 891 passageiros, o que pode limitar a generalização
2. Dados Faltantes: Informações como idade e cabine não estavam completas para todos os passageiros
3. Viés Histórico: O conjunto de dados reflete apenas os passageiros registrados

Implicações Práticas

Os insights gerados podem ser aplicados em:

- Planejamento de Emergências: Priorização de grupos vulneráveis

- Análise de Risco: Identificação de fatores de risco em situações críticas
- Políticas Públicas: Desenvolvimento de protocolos de evacuação

Conclusão

Este trabalho demonstrou a aplicação bem-sucedida de técnicas de machine learning para análise do desastre do Titanic. O pipeline desenvolvido alcançou uma acurácia de 0.8283, identificando fatores-chave para a sobrevivência.

Os resultados confirmam a importância de variáveis socioeconômicas e demográficas na determinação do prognóstico em situações de emergência. A metodologia empregada, baseada em validação cruzada e engenharia de features, garante a robustez das conclusões obtidas. Este estudo contribui para o campo da análise de dados aplicada a contextos históricos, demonstrando como técnicas modernas de ML podem extrair insights valiosos de conjuntos de dados limitados. As lições aprendidas com o Titanic continuam relevantes para o planejamento de segurança contemporâneo.

Configuração Técnica

Ambiente de Desenvolvimento

- Linguagem: Python 3.8+
- Bibliotecas Principais: scikit-learn, pandas, numpy, matplotlib
- Validação: 5-fold cross-validation estratificada
- Métricas: Acurácia, AUC-ROC, precisão, recall, F1-score

Configuração do Pipeline

```
''' {} '''
```

Visualizações Geradas

As seguintes visualizações foram geradas e salvas no diretório output/graficos/:

1. Matriz de Confusão: output/graficos/03_matriz_confusao.png
2. Curvas ROC: output/graficos/roc_curves/04_roc_curve.png
3. Heatmap de Correlação: output/graficos/correlation/09_feature_correlation_heatmap.png
4. Timeline de Performance: output/graficos/timeline/10_model_performance_timeline.png
5. Importância de Features: output/graficos/feature_importance/
6. Plots de Calibração: output/graficos/calibration/

Relatório gerado em: 05/01/2026 00:25:58 - Pipeline Titanic ML - Versão 5.0